

Analisis de Malware en Android con NATICUSdroid

Claudia Maria Rocha Hernandez, Sebastian Bedoya Restrepo, David Guillermo Naranjo Ochoa

Resumen—Este trabajo presenta la fase inicial de un sistema de detección de malware en aplicaciones Android utilizando el dataset NATICUSdroid. Debido al aumento de aplicaciones maliciosas que explotan el sistema de permisos, se plantea un enfoque de aprendizaje supervisado formulado como un problema de clasificación binaria. Se analiza la estructura del dataset, compuesto por más de 29000 aplicaciones y 86 características basadas en permisos, con el fin de comprender su comportamiento y su utilidad para el modelado. Adicionalmente, se revisan trabajos relacionados que evidencian la efectividad de modelos de ensamble y técnicas de selección de características en este tipo de problemas. Estos elementos permiten establecer una base clara para el desarrollo de modelos de detección en etapas posteriores.

Index Terms—Android, malware detection, machine learning, binary classification, feature selection

I. INTRODUCCION

ANDROID, desarrollado por Google, es actualmente el sistema operativo móvil más utilizado a nivel mundial, con miles de millones de dispositivos activos y un amplio ecosistema de aplicaciones distribuidas tanto en tiendas oficiales como en repositorios de terceros. Sin embargo, esta masificación también lo convierte en un blanco atractivo para el desarrollo de software malicioso. Distintos reportes han evidenciado incidentes en los que aplicaciones aparentemente legítimas explotan vulnerabilidades del sistema o recolectan información sensible.

En el contexto de la seguridad informática, la revisión manual del código ha sido una estrategia tradicional, aunque costosa y limitada. Por esta razón, han surgido enfoques basados en el análisis del comportamiento, especialmente a través de los permisos solicitados por las aplicaciones. Estos permiten inferir accesos a recursos sensibles y detectar patrones anómalos. Investigaciones previas han demostrado una relación significativa entre ciertos conjuntos de permisos y la presencia de malware en Android [3].

El dataset NATICUSdroid recopila información de más de 29000 aplicaciones clasificadas como benignas o maliciosas. Esto permite aplicar técnicas de aprendizaje automático para abordar el problema como una tarea de clasificación binaria.

El desarrollo de estos sistemas resulta relevante para fortalecer la seguridad en Android, mejorar la detección temprana de amenazas y comprender la evolución del malware.

Claudia Maria Rocha Hernandez: claudia.rochah@udea.edu.co
Sebastian Bedoya Restrepo: sebastian.bedoya7@udea.edu.co
David Guillermo Naranjo Ochoa: guillermo.naranjo@udea.edu.co

II. DESCRIPCION DEL PROBLEMA

II-A. Contexto del problema

En el contexto actual de la seguridad en dispositivos móviles, la detección de aplicaciones maliciosas en Android se ha convertido en un desafío relevante debido al crecimiento constante de amenazas cada vez más sofisticadas. Los enfoques tradicionales basados en firmas, comúnmente utilizados por soluciones antivirus, han perdido efectividad frente a malware moderno que emplea técnicas como la ofuscación y la mutación de código para evadir mecanismos de detección estáticos.

Ante esta limitación, el uso de técnicas de Machine Learning surge como una alternativa adecuada, ya que permite analizar grandes volúmenes de datos y descubrir patrones complejos que no son evidentes mediante enfoques tradicionales. En particular, el análisis de los permisos solicitados por las aplicaciones representa una fuente de información clave, dado que estos reflejan el nivel de acceso al sistema y pueden evidenciar comportamientos potencialmente maliciosos. Estudios previos han demostrado que existe una relación significativa entre ciertos conjuntos de permisos y la presencia de malware en Android [3].

En este contexto, el presente trabajo aborda el problema de la detección automática de malware mediante técnicas de aprendizaje automático, partiendo de un análisis exploratorio del dataset y culminando en la definición de un modelo de clasificación capaz de discriminar entre aplicaciones benignas y maliciosas.

II-B. Composición de la Base de Datos

El dataset utilizado corresponde a NATICUSdroid (Android Permission Dataset), el cual se encuentra disponible en el repositorio UCI Machine Learning. Este conjunto de datos está compuesto por 29333 instancias y 86 variables, donde cada instancia representa una aplicación Android clasificada como benigna o maliciosa, definiendo así un problema de clasificación binaria.

Las variables del dataset corresponden a permisos solicitados por las aplicaciones. Cada característica representa un permiso específico del sistema Android, y su valor indica su presencia (1) o ausencia (0) en la aplicación. Esta representación permite modelar el comportamiento de las aplicaciones mediante un enfoque de análisis estático basado en permisos, ampliamente utilizado en el ámbito de la ciberseguridad.

En cuanto a la codificación, las variables independientes son de tipo binario, mientras que la variable objetivo, denominada *Result*, es también binaria y representa la clase de la aplicación (0 para aplicaciones benignas y 1 para aplicaciones maliciosas). Este tipo de estructura

resulta especialmente adecuado para modelos de aprendizaje supervisado, ya que no requiere transformaciones adicionales y facilita la aplicacion de algoritmos clasicos como Random Forest, Maquinas de Vectores de Soporte y Regresion Logistica.

Un aspecto relevante del dataset es la ausencia de valores faltantes, lo que elimina la necesidad de aplicar tecnicas de imputacion y simplifica el preprocesamiento de los datos. Adicionalmente, al tratarse de un conjunto de datos tabular con variables discretas binarias, no es necesario realizar procesos de normalizacion, lo cual favorece el uso de modelos basados en arboles. No obstante, es posible la existencia de redundancia entre permisos, lo que sugiere la aplicacion de tecnicas de seleccion de caracteristicas en etapas posteriores.

En conjunto, estas caracteristicas hacen que el dataset NATICUSDroid sea adecuado para tareas de clasificacion en ciberseguridad, al proporcionar una representacion estructurada y consistente del comportamiento de las aplicaciones.

II-C. Paradigma de Aprendizaje y Justificacion

El enfoque seleccionado para abordar el problema es el Aprendizaje Supervisado, formulado como una tarea de Clasificacion Binaria. Esta decision se fundamenta en la estructura del dataset, donde cada instancia cuenta con una etiqueta de salida que indica si la aplicacion es benigna o maliciosa. La disponibilidad de datos etiquetados permite entrenar modelos capaces de aprender una funcion de mapeo entre los patrones de permisos y la clase correspondiente, facilitando la prediccion sobre nuevas aplicaciones no observadas previamente.

Desde una perspectiva tecnica, esta formulacion es coherente con la naturaleza del problema, ya que se busca discriminar entre dos estados mutuamente excluyentes. El espacio de caracteristicas, compuesto por variables binarias, permite capturar relaciones complejas entre permisos, lo que resulta adecuado para modelos capaces de manejar alta dimensionalidad. Asimismo, este enfoque permite evaluar el desempeno mediante metricas relevantes en seguridad informatica, como la tasa de falsos positivos y la medida F, las cuales son fundamentales para minimizar errores criticos en la deteccion.

Adicionalmente, la seleccion de este paradigma es consistente con lo reportado en la literatura reciente. Estudios como el de Mathur et al. [2] han demostrado el alto desempeno de modelos supervisados en la deteccion de malware en Android, mientras que propuestas como la de Feng y Zhang [1] evidencian la importancia de integrar tecnicas de seleccion de caracteristicas para optimizar el rendimiento en entornos dinamicos. Estos enfoques seran abordados con mayor detalle en la siguiente seccion.

III. ESTADO DEL ARTE

El estudio de la seguridad en el ecosistema Android ha evolucionado para enfrentar amenazas que explotan el sistema de permisos con el fin de comprometer la

privacidad del usuario. En este contexto, Mathur et al. [2] proponen el framework NATICUSDroid, cuyo objetivo principal es superar las limitaciones de estudios previos basados en conjuntos de datos obsoletos. Su enfoque se centra en la relevancia de los permisos tanto nativos del sistema operativo como personalizados. Para ello, los autores realizan un analisis estadistico sobre una base de datos de mas de 29000 aplicaciones recolectadas entre 2010 y 2019, aplicando tecnicas de seleccion de caracteristicas y evaluando multiples algoritmos de aprendizaje automatico. Los resultados obtenidos indican que el modelo basado en Random Forest presenta el mejor desempeno, alcanzando una precision cercana al 97%, lo que demuestra que la combinacion de permisos actuales constituye un predictor robusto para la deteccion de malware moderno.

Por otro lado, la necesidad de gestionar de forma eficiente grandes volúmenes de caracteristicas, como los presentes en el dataset NATICUSDroid, es abordada en el trabajo de Feng y Zhang [1]. Estos autores analizan el problema desde una perspectiva de optimizacion en la seleccion de caracteristicas dentro de entornos dinamicos. Su propuesta introduce un metodo de seleccion incremental basado en un vector de regularizacion, el cual permite actualizar la informacion sin necesidad de reentrenar completamente los modelos. Este enfoque resulta especialmente relevante en escenarios donde los datos evolucionan constantemente, como ocurre con la aparicion continua de nuevas aplicaciones y permisos en Android. Los resultados experimentales muestran que este metodo supera a tecnicas convencionales, lo que sugiere su potencial integracion en sistemas de deteccion de malware para mejorar su eficiencia y capacidad de adaptacion en entornos reales.

REFERENCIAS

- [1] Z. Feng and X. Zhang, "Supervised incremental feature selection using regularization vector for dynamic multi-scale interval valued datasets," *Pattern Recognition*, vol. 170, p. 111985, 2026.
- [2] A. Mathur et al., "NATICUSDroid: A malware detection framework for Android," *Journal of Information Security and Applications*, vol. 58, p. 102696, 2021.
- [3] B. Sanz et al., "Permission usage to detect malware in Android," *International Joint Conference*, pp. 121–130, 2013.